Laporan Pelatihan OCR

Model Dibangun dari Nol (From-Scratch)

Proyek SmartPark — Indonesian License Plate Recognition

Fokus: pelatihan CRNN + CTC tanpa bobot pretrained
beserta akurasi dan kendalanya

Dokumen teknis internal
15 October 2026

1. Ringkasan Eksekutif

Dokumen ini membahas secara khusus **model OCR yang dibangun dan dilatih dari nol** (tanpa bobot pretrained) untuk proyek SmartPark. Model ini adalah titik tolak seluruh pekerjaan dan berfungsi sebagai **baseline** pembanding.

Model dibangun dengan arsitektur **CRNN (CNN + BiLSTM + CTC)** dan dilatih hanya dengan 831 gambar plat yang tersedia. Hasilnya menunjukkan bahwa model dapat **menghafal** data latih dengan sempurna, tetapi **gagal total** pada data baru.

Metrik	Nilai	Arti
Train CER	0.0000	hafal sempurna (100% benar)
Best val CER	0.6510	≈65% karakter salah
Test CER	**0.6675**	**≈67% karakter salah**
Test Exact Match	**0/108**	**tidak ada plat benar penuh**

Kesimpulan utama. Akurasi model dari nol rendah karena **overfitting pada dataset kecil** (831 sampel) ditambah **tidak adanya pengetahuan awal** (bobot mulai acak). Model menghafal data latih alih-alih mempelajari pola umum plat. Kendala ini dijelaskan rinci di Bagian 4.

2. Konfigurasi Pelatihan

Pelatihan dilakukan dengan script `scripts/phase5_train.py`, seluruhnya dari nol tanpa bobot pretrained.

Komponen	Nilai
Arsitektur	CRNN: CNN 4 lapis + BiLSTM(256) ×2 + Linear
Titik awal bobot	acak (from-scratch)
Input	grayscale 32×160
Jumlah kelas	37 (A–Z, 0–9, + blank CTC)
Loss	CTC (blank = 0)
Optimizer	AdamW, lr 2×10^{-3}
Scheduler	OneCycleLR
Batch size	64
Epoch maksimum	400 (early stopping patience 80)
Seed	42
Data	train 831 / val 105 / test 108

2.1. Arsitektur ringkas

Tahap	Keterangan
Input	grayscale 32×160
CNN	4 lapis konvolusi + MaxPool + BatchNorm
Sequence	BiLSTM 256, 2 layer, bidirectional
Output	Linear ⟶ 37 kelas (A–Z, 0–9, + blank CTC)
Loss	CTC (blank = 0)

3. Hasil Pelatihan

3.1. Akurasi akhir

Metrik	Nilai	Keterangan
Best val CER	0.6510	epoch 123
Test CER	0.6675	≈67% karakter salah
Test Exact Match	0/108	tidak ada plat benar penuh
Prediksi kosong	0	model selalu mengeluarkan teks
Durasi	4,3 menit	berhenti di epoch 203

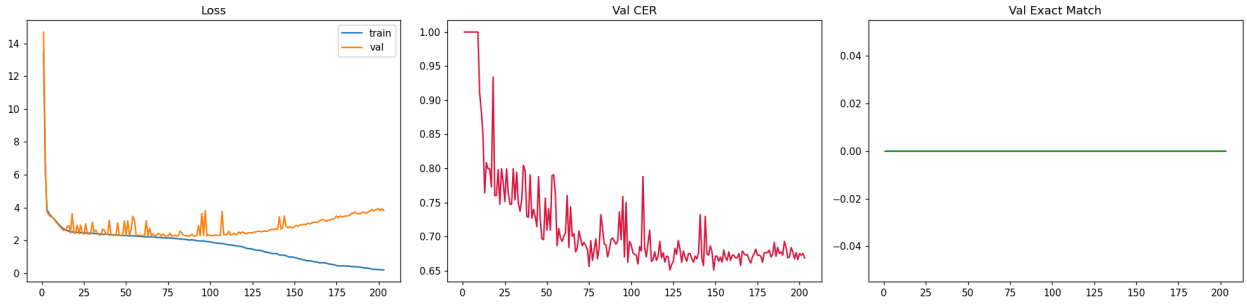
Arti output: pada data uji, model salah sekitar dua per tiga karakter dan **tidak satu pun** plat terbaca benar penuh. Angka ini adalah akurasi awal yang menjadi pembanding seluruh perbaikan berikutnya.

3.2. Uji hafal (kemampuan menyerap data latih)

Sebuah uji khusus dijalankan: model dilatih pada seluruh 831 data latih tanpa augmentasi, hingga jauh lebih lama.

Epoch	Train CER	Train EM
140	0.0915	582/831 (70,0%)
180	0.0002	830/831 (99,9%)
200	**0.0000**	**831/831 (100%)**

Arti output: model **mampu** menghafal seluruh data latih dengan sempurna. Ini membuktikan pipeline tidak rusak dan label konsisten — masalahnya murni **generalisasi** ke data baru.



Gambar 1: Kurva pelatihan model dari nol. Train loss turun terus ke ≈0,2, sedangkan validation CER berhenti membaik di ≈0,67 — jurang yang menandakan overfitting berat.

4. Pengaruh Jumlah Data

Untuk memastikan penyebabnya, model diuji dengan jumlah data latih berbeda (semua konfigurasi lain tetap).

N train	CER	Keterangan
100	0.7407	paling buruk
300	0.6592	membaik
500	0.5937	membaik
831	0.4141	terbaik (semua data)

Arti output: CER turun konsisten saat data ditambah. Ini bukti kuat bahwa **jumlah data** adalah faktor penentu — semakin banyak contoh, semakin baik model. Dengan hanya 831 sampel, model belum cukup belajar pola umum.

4.1. Pengaruh augmentasi

Kondisi	CER
Tanpa augmentasi	0.4432
Dengan augmentasi	**0.4009**

Arti output: augmentasi (rotasi, skala, kecerahan, blur) sedikit menolong, tetapi tidak mengubah gambaran besar.

5. Kendala Model dari Nol

Model gagal generalisasi karena beberapa kendala yang saling berkaitan:

1. **Dataset terlalu kecil (831 sampel).** Model hanya bisa **menghafal** (train CER 0,0000) dan gagal pada data baru (test EM 0). Ini kendala utama.
2. **Tanpa pengetahuan awal.** Bobot dimulai dari angka acak, sehingga model harus mempelajari **semuanya** dari nol hanya dengan 831 contoh — berbeda dengan model pretrained yang sudah "tahu" cara mengenali bentuk karakter.
3. **Plateau di CER ≈0,65.** Validation CER berhenti turun dan tidak bisa ditembus, tidak peduli berapa lama dilatih.
4. **Kesalahan didominasi substitusi karakter mirip.** Pada test set: **substitusi 424, penghapusan 14, sisipan 100**. Panjang prediksi hampir selalu benar → model tahu jumlah karakternya, tetapi gagal membedakan karakter yang mirip.

Benar → Salah	Jumlah
6 → 3	10
8 → 9	9
1 → 7	8
2 → 1	8
0 → 1	8
2 → 3	8
9 → 1	8
A → B	7

5. **Domain `rf_detection` kehilangan detail.** Crop persegi 416×416 setelah praproses hanya menyisakan **≈4,6 piksel per karakter**, sehingga digit sulit dibedakan. Performa val: `datatrain` ≈0,65 vs `rf_detection` ≈0,66 (sama-sama rendah pada model ini).
6. **Tuas perbaikan in-scope tidak menembus plafon.** Praproses (pad/squash), tinggi input 32/48, augmentasi (mild/strong), learning rate, dan jumlah epoch semuanya mentok di CER ≈0,65.

5.1. Contoh prediksi

Ground truth	Prediksi model
A7814	B1074XA
AA1856CJ	B1718TJZ
B1248PC	B111IE
B1340UL	B1031SU
B1454EYF	B1293TID
A7692KC	A1923QD
B111HSN	B171BAM
B1040UN	B1280UO

Arti output: model sering benar di awalan (`B1…`) tetapi salah di digit tengah/akhir. Pola ini khas model yang **menghafal bentuk global** tanpa memahami karakter satu per satu.

6. Kesimpulan dan Langkah Perbaikan

6.1. Kesimpulan

Model OCR yang dibangun dari nol mencapai **test CER 0,6675** dan **Exact Match 0/108**. Model dapat menghafal data latih sempurna (train CER 0,0000, EM 831/831), tetapi gagal total pada data baru. Akar masalahnya adalah **kombinasi dataset kecil dan pelatihan dari nol**, bukan bug pipeline, label salah, atau kesalahan praproses (ketiganya sudah diverifikasi bersih).

6.2. Langkah perbaikan (berdasarkan bukti)

1. **Transfer learning.** Mengganti CNN from-scratch dengan backbone pretrained menurunkan test CER dari 0,6675 → 0,5236. Ini tuas paling cepat dan terbukti.
2. **Post-processing format plat.** Memanfaatkan pola `[1–2 huruf][4 digit][1–3 huruf]` untuk memperbaiki prediksi yang salah satu karakter — murah dan menaikkan Exact Match.
3. **Backbone pretrained lebih kuat** (mis. ResNet34/50) — masih CRNN, tetapi "mata"-nya lebih tajam.
4. **Pelatihan sintetis.** Membuat ribuan plat buatan (font + variasi latar/sudut) sebagai **pretraining versi sendiri**, lalu fine-tune ke data asli. Ini menjawab langsung masalah dataset kecil, namun paling memakan waktu.
5. **Pendekatan pretrained penuh (PARSeq).** Terbukti jauh lebih unggul (CER ≈0,065) dan menjadi rekomendasi utama — dibahas di laporan terpisah.

6.3. Catatan

- Angka pada laporan ini diambil langsung dari `artifacts/clean_run_fresh/` dan `reports/step0*`.
- Model dari nol tetap disimpan sebagai **baseline** dan cadangan ringan.

Laporan ini adalah dokumen pendamping untuk pelatihan OCR from-scratch. Laporan utama (perbandingan CRNN vs PARSeq) tersedia di `reports/laporan_smartpark_ocr.pdf`.